DESCRIPCIÓN

Título de la invención

Método y sistema de computación condicional con reservorio de neuronas direccionables y selección de cardinalidad exacta.

Sector de la técnica

La invención pertenece al procesamiento de datos mediante redes neuronales de computación condicional. En particular concierne a una capa que, para cada elemento de una secuencia, ejecuta una transformación no lineal solo sobre un subconjunto de cardinalidad fijada de un reservorio de neuronas direccionables, y al entrenamiento de los parámetros que deciden ese subconjunto. La aplicación preferente es un modelo de lenguaje que predice el elemento siguiente. La capa sirve también para otras secuencias de representaciones vectoriales.

Clasificación internacional sugerida, que la Oficina asignará de oficio: G06N 3/04 (arquitecturas de redes neuronales) y G06N 3/08 (métodos de aprendizaje). El reparto del presupuesto entre capas, cuando se usa, admite además G06F 9/50.

Estado de la técnica anterior conocido por el solicitante

Las redes de transformación usadas en modelos de lenguaje aplican, en cada capa, atención y una red de avance de posición a posición. El coste de esa red de avance crece con su anchura. La computación condicional activa solo una parte de los parámetros en cada elemento.

Shazeer y otros, «Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer», arXiv:1701.06538, 2017, describen una mezcla de expertos con puerta dispersa. Lepikhin y otros, «GShard», arXiv:2006.16668, 2020, y Fedus, Zoph y Shazeer, «Switch Transformers», arXiv:2101.03961, 2021, escalan esa mezcla: un encaminador elige, por elemento, los k expertos de mayor puntuación, a menudo con una pérdida auxiliar de equilibrio de carga. La unidad encaminada es un bloque de avance entero.

Dai y otros, «DeepSeekMoE», arXiv:2401.06066, 11 de enero de 2024, segmentan los expertos en un grano más fino y aíslan expertos compartidos que permanecen activos para todos los elementos. El informe técnico DeepSeek-V3, arXiv:2412.19437, 2024, ajusta un sesgo por experto según la carga, sin pérdida auxiliar de equilibrio. «Scaling Laws for Fine-Grained Mixture of Experts», arXiv:2402.07871, 12 de febrero de 2024, estudia la granularidad del experto como hiperparámetro. Chen y otros, «MobileMoE», arXiv:2605.27358, 26 de mayo de 2026, entrenan mezclas para dispositivo con

expertos finos y un experto compartido; el modelo público de la escala S usa 60 expertos encaminados, cuatro activos y un experto compartido. En todos estos documentos la unidad de selección sigue siendo un experto de muchas neuronas, y las neuronas de un experto se activan juntas.

He, «Mixture of a Million Experts», arXiv:2407.04153, 4 de julio de 2024, presenta la capa PEER: expertos de una sola neurona recuperados con claves producto (Lample y otros, «Large Memory Layers with Product Keys», NeurIPS 2019). La recuperación aproxima la búsqueda entre un número muy grande de claves y combina las salidas de los expertos recuperados con coeficientes normalizados del encaminador. Berges y otros, «Memory Layers at Scale», arXiv:2412.09764, 12 de diciembre de 2024, añaden una memoria clave-valor de gran capacidad; la lectura devuelve valores, no la salida de una neurona SwiGLU con puerta, proyección ascendente y proyección descendente propias. Raposo y otros, «Mixture-of-Depths», arXiv:2404.02258, 2024, reparten cómputo dejando que algunos elementos salten una capa. Bengio, Léonard y Courville, «Estimating or Propagating Gradients Through Stochastic Neurons for Conditional Computation», arXiv:1308.3432, 2013, describen estimadores de paso directo para neuronas discretas.

Jaszczur y otros, «Sparse is Enough in Scaling Transformers», arXiv:2111.12763, 24 de noviembre de 2021, describen una red de avance dispersa en la que un controlador de rango bajo, xC_1C_2, produce un logit por neurona. Las neuronas de la capa de avance se dividen en bloques consecutivos de tamaño fijo, y el controlador activa exactamente una neurona en cada bloque, por máximo dentro del bloque. En entrenamiento usa un estimador de paso directo de tipo Gumbel-softmax con ruido y temperatura, y en parte de los pasos hacia delante usa la salida suave del softmax. En inferencia solo se leen las filas y columnas de las neuronas activadas. La capa dispersa sustituye a una capa de avance de la misma anchura total: el documento no amplía el número total de neuronas manteniendo el número de activas, ni mide la conversión de esa capacidad en calidad. Liu y otros, «Deja Vu: Contextual Sparsity for Efficient LLMs at Inference Time», arXiv:2310.17157, 2023, predicen en inferencia qué neuronas de un modelo denso ya entrenado conviene calcular; la selección no forma parte del entrenamiento del modelo.

La solicitud internacional WO 2025/217570 A1, «Neural networks with parameter efficient expert retrieval», de DeepMind Technologies Ltd y GDM Holding LLC, con prioridad de 12 de abril de 2024, reivindica una capa con un gran número de expertos, cada uno asociado a una clave. Una red de consulta produce una consulta, se calcula el producto interno de la consulta con la clave de cada experto y se seleccionan como máximo k de un total de N, con N de al menos un millón. En una reivindicación

dependiente, cada experto es un perceptrón de una sola neurona. En las reivindicaciones dependientes y en la descripción, las claves se forman con subclaves compartidas (claves producto), y los coeficientes de los expertos elegidos proceden de una puerta sigmoide o softmax. El documento no describe un vector de afinidad propio de cada neurona normalizado, ni una excitabilidad basal sumada al coseno, ni una neurona SwiGLU con puerta y ascenso propios. Tampoco describe un desempate por identidad estable, un estimador de paso directo con máscara rígida hacia delante ni un perceptrón compartido siempre activo.

Chi y otros, «On the Representation Collapse of Sparse Mixture of Experts» (X-MoE), arXiv:2204.09179, 20 de abril de 2022, parametrizan cada experto con una incrustación de dimensión mucho menor que la del estado y lo puntúan con el coseno entre una proyección lineal del estado y esa incrustación. La unidad es un experto completo, elegido con top-1, y la puntuación no lleva excitabilidad propia. La publicación de patente US 2024/0169463 A1, de Microsoft, prioridad de 10 de noviembre de 2022, describe también un encaminamiento por similitud coseno seguido de los k mayores valores, con k variable, a nivel de experto.

Varios documentos seleccionan neuronas individuales de la red de avance. Li y otros, «The Lazy Neuron Phenomenon», arXiv:2210.06313, 2022, y Wang y otros, «Q-Sparse», arXiv:2407.10969, 15 de julio de 2024, conservan en el entrenamiento solo las K mayores activaciones. Q-Sparse pasa el gradiente a través de la máscara sin modificarlo, como un estimador de paso directo identidad. Cheng y otros, «Mixture of Neuron Experts» (MoNE), arXiv:2510.05781, 7 de octubre de 2025, eligen dentro de cada experto ya encaminado las neuronas SwiGLU de mayor valor absoluto de puerta, leen solo sus filas y usan un experto compartido. «CATS», arXiv:2404.08763, 2024, y You y otros, «Spark Transformer», arXiv:2506.06644, 7 de junio de 2025, deciden las neuronas activas de una capa SwiGLU con un umbral, calculan antes la parte barata y cargan después solo las filas de las neuronas activas. Spark estima el umbral con la media y la desviación de las puntuaciones, sin ordenar, y obtiene aproximadamente, no exactamente, la cardinalidad buscada. Huang y otros, «Ultra-Sparse Memory Network» (UltraMem), arXiv:2411.12364, 19 de noviembre de 2024, seleccionan de forma exacta los mayores valores sobre una memoria dispersa descompuesta por filas y columnas. En todos estos documentos la puntuación que decide la neurona es su propia activación, una parte de sus pesos o una clave compuesta, no un vector de afinidad propio y normalizado de dimensión reducida más una excitabilidad. Ninguno amplía el número total de neuronas a número de activas fijo y mide la conversión de esa capacidad en calidad frente a una mezcla de expertos del mismo bloque.

Zhu y otros, «DFTopK», arXiv:2510.11472, 2025, en el campo de la recomendación, definen un operador suave de selección de los k mayores, $\sigma((x - \theta)/\tau)$, con θ igual al punto medio entre el k-ésimo y el (k+1)-ésimo valor, y lo usan como salida suave en una pérdida de ordenación. No lo usan como gradiente sustituto de una máscara rígida que es el valor hacia delante. La patente US 12518135 B2, de Google, sustituye la selección de los k mayores en una mezcla de expertos por una función de paso suave diferenciable, sin máscara rígida hacia delante.

Frente a esos documentos, la invención reúne en una misma capa varias características que ninguno de ellos combina.

La unidad direccionable es una neurona SwiGLU con puerta, ascenso y salida propios. Esa neurona se decide por un vector de afinidad propio, de dimensión reducida, no compuesto con subclaves compartidas con otras neuronas y distinto de sus propios pesos. La puntuación es el coseno entre una consulta y esa afinidad, ambas normalizadas, más una excitabilidad basal acotada. La acotación limita cuánto puede una neurona imponerse a la afinidad del contexto.

La capa elige exactamente K neuronas entre todas las N del reservorio, sin partición en bloques ni en expertos, de modo que el número de neuronas activas de una zona del reservorio no está fijado de antemano. El orden de selección es determinista, con desempate por una identidad estable y sin ruido añadido.

El valor hacia delante es siempre la máscara rígida, también en entrenamiento, así que la red que se entrena es la misma que se ejecuta en inferencia. El gradiente de las puntuaciones procede de una sigmoide centrada en el punto medio, destacado del grafo, entre la última puntuación seleccionada y la primera excluida. No es el gradiente identidad de una máscara ni la salida de un operador suave.

El reservorio es varias veces mayor que la cuota activa, y los ensayos miden una mejora al ampliarlo con la cuota fija, frente a una mezcla de expertos construida con el mismo bloque que no la obtiene. Ese es el efecto técnico: una misma cantidad de cálculo pesado por elemento produce una predicción mejor cuando crece la memoria de parámetros, y esa memoria no hay que leerla entera en inferencia.

El solicitante conoce, por ensayos propios reproducibles que se exponen más adelante, un límite concreto de la mezcla de expertos cuando el bloque, los datos, el optimizador y la evaluación se mantienen iguales. Duplicar el número de expertos de anchura fija, manteniendo el número de expertos activos, no redujo la entropía cruzada de desarrollo. Duplicar un reservorio de neuronas direccionables, manteniendo el número de neuronas pesadas activas, sí la redujo.

Problema técnico

Hace falta una capa de computación condicional en la que aumentar el número de parámetros totales, sin aumentar el número de neuronas pesadas que se ejecutan por elemento, mejore la predicción del elemento siguiente de forma estable. La capa tiene que componer, para cada elemento, un circuito distinto tomado de un reservorio grande, con una cardinalidad exacta y reproducible, y tiene que dejar gradiente en los parámetros que deciden esa composición aunque la decisión sea discreta. El coste de memoria de la inferencia, cuando el ejecutor materializa solo las filas elegidas, debe depender de la cardinalidad activa y no del tamaño del reservorio.

Explicación de la invención

La invención es un método implementado por ordenador, un sistema que lo ejecuta y un programa que lo realiza. Una capa mantiene un reservorio de N neuronas. Cada neurona es una unidad SwiGLU con tres vectores propios: puerta, proyección ascendente y proyección descendente. Cada neurona tiene además un vector de afinidad de dimensión g menor que la dimensión d del estado, un escalar de excitabilidad basal y una identidad estable distinta del índice de almacenamiento.

Para cada elemento, la capa calcula una consulta normalizada a partir del estado residual y una puntuación de las N neuronas. La puntuación es el producto escalar de la consulta por la afinidad normalizada, más la excitabilidad limitada a un intervalo. Las puntuaciones no se alteran con un término que dependa de la identidad. Un selector toma exactamente K neuronas según el orden lexicográfico de puntuación decreciente e identidad estable creciente. En el cálculo hacia delante, la contribución del reservorio es la suma de las salidas de las neuronas seleccionadas, con coeficiente uno, y cero en las demás. Esa máscara rígida es el valor hacia delante. En el entrenamiento, un estimador de paso directo sustituye el gradiente de la máscara por el de una sigmoide centrada en el punto medio, destacado del grafo, entre la menor puntuación seleccionada y la mayor puntuación excluida. La cuota K no recibe gradiente a través de esa máscara.

En el modo preferente, un perceptrón SwiGLU compartido de anchura pequeña permanece activo para todos los elementos. El estado que entra al reservorio se normaliza, y la suma del perceptrón compartido y de la contribución del reservorio se normaliza antes de añadirse al residual.

El efecto técnico medido, con el mismo bloque, los mismos datos, el mismo optimizador y la misma evaluación, es el siguiente. Con cuota media de 1024 neuronas pesadas por capa, pasar el reservorio de 8192 a 16384 neuronas por capa redujo la entropía cruzada de desarrollo a los 100 millones de elementos en 0,038 nat de media

en tres semillas emparejadas (0,042, 0,040 y 0,032). La mezcla de expertos del mismo bloque, al pasar de 64 a 128 expertos de anchura 128 con ocho expertos activos, no redujo la entropía cruzada (diferencias +0,002, 0,000 y +0,036). A igualdad aproximada de parámetros totales y de neuronas pesadas activas, el reservorio de 16384 quedó por debajo de la mezcla de 128 expertos en las tres semillas, con media de −0,047 nat a los 100 millones y de −0,034 nat a los 200 millones. El alcance de estos ensayos se declara en el modo de realización: una anchura, un corpus, un conjunto de desarrollo, y una varianza entre entornos de ejecución del orden de la diferencia más pequeña.

La identidad estable hace el desempate determinista entre ejecuciones y permite reordenar el almacenamiento sin cambiar qué neurona gana un empate. Un procedimiento para ampliar el reservorio después del entrenamiento, conservando la función calculada en el instante de la inserción, es objeto de una solicitud distinta del mismo solicitante; esta descripción no lo reivindica.

Ventajas

La combinación posible de neuronas por elemento es la de los subconjuntos de tamaño K dentro de N, y no la de los subconjuntos de expertos. Con la cuota media fija, el reservorio mayor mejora la predicción en los ensayos citados, mientras la mezcla de expertos del mismo bloque no convierte esa duplicación. La cardinalidad hacia delante es exacta. Los empates no dependen del orden inespecificado de una ordenación parcial ni de una perturbación añadida a la puntuación. El encaminador recibe gradiente aunque la máscara hacia delante sea rígida. En inferencia, un ejecutor que lee solo las filas seleccionadas mueve K filas de pesos pesados por elemento y capa, con independencia de N. El perceptrón compartido y las dos normalizaciones, la de entrada del reservorio y la posterior sobre la suma, forman el bloque con el que se obtuvieron las cifras. Añadir esas dos normalizaciones a un bloque de pre-normalización sola redujo la entropía cruzada del orden de 0,09 nat en el reservorio y de 0,11 nat en la mezcla de expertos del mismo bloque.

Breve descripción de los dibujos

La figura 1 es un esquema de la red completa.

La figura 2 es un esquema de una capa y es la figura característica para el resumen.

La figura 3 es un esquema del cálculo de puntuaciones y de la selección de cardinalidad exacta.

La figura 4 es un esquema del estimador de paso directo usado en el entrenamiento.

La figura 5 es un esquema de dos ejecutores del reservorio: producto denso enmascarado y lectura por índices.

Exposición detallada de un modo de realización

Red y dimensiones del ejemplo.

La red (10) de la figura 1 es un descodificador de L capas (12) iguales en estructura. En el ejemplo medido, L = 14 y la dimensión del estado d = 1024. Un embebido ligado a la proyección de salida convierte identificadores discretos en vectores. Tras la última capa, una normalización final precede a esa proyección. Los identificadores de vocabulario no usados se enmascaran a menos infinito antes de la entropía cruzada. El ejemplo usa 50304 filas de embebido y 50280 identificadores válidos, los del tokenizador público OLMoE (Muennighoff y otros, arXiv:2409.02060, 2024), revisión 6d84c48581ece794365f2b8e9cfb043c68ade9c5, con fin de documento 50279 y relleno 1. Esos números de vocabulario son del ejemplo, no un límite de la invención.

Cada elemento de una ventana lleva una posición que se reinicia en la frontera de documento y un identificador de documento. La atención es causal y, además, solo atiende a posiciones del mismo documento. Así, el relleno y el documento vecino no entran en la atención ni en la pérdida. La atención del ejemplo es de consultas agrupadas: 16 cabezas de consulta, 4 de clave y valor, dimensión 64, rotación posicional de base 10000 en convención de mitades, sin sesgos y sin abandono.

Capa.

La figura 2 muestra una capa (12). Sea x la representación de entrada de un elemento. La capa calcula:

r = x + Atención(RMSNorm_atención(x))

F = Compartido(RMSNorm_compartido(r))

r_in = RMSNorm_reservorio(r)

D = suma de las contribuciones de las neuronas seleccionadas del reservorio, evaluadas en r_in

y = r + RMSNorm_posterior(F + D)

RMSNorm de un vector u, con escala aprendida γ y épsilon 1e−5, es u dividido por la raíz cuadrada de la media de sus cuadrados más épsilon, multiplicado por γ. En el ejemplo se calcula en precisión de 32 bits. El estado residual (24) es r.

El modo medido es el de las dos normalizaciones añadidas: una a la entrada del reservorio y otra sobre la suma F + D. Dos variantes implementadas sirven de

comparación. En la variante literal, el reservorio recibe r sin normalización propia y la suma F + D sí se normaliza. En la variante de pre-normalización sola, no hay normalización posterior y el reservorio recibe r. El paso de la pre-normalización sola a la variante medida redujo, a los 100 millones de elementos y en una semilla, la entropía cruzada de 3,966 a 3,874 en el reservorio y de 3,992 a 3,878 en la mezcla de expertos del mismo bloque. La invención puede realizarse con cualquiera de las tres colocaciones; la colocación medida es la preferente y es la de la reivindicación dependiente correspondiente.

Perceptrón compartido.

El perceptrón compartido (32) es un SwiGLU de anchura fija, 128 en el ejemplo, siempre activo, sin sesgos. Su anchura es menor que la cuota media de neuronas pesadas (128 frente a 1024) y menor que la cuota mínima de capa usada con el registro de presupuesto (768). Calcula puerta, proyección ascendente y proyección descendente sobre el estado normalizado, con la misma definición SwiGLU que cada neurona del reservorio.

Neurona del reservorio.

El reservorio (42) tiene N neuronas (44) por capa. Cada neurona i posee vectores W^g_i y W^u_i de dimensión d y un vector de salida W^d_i de dimensión d. Con entrada r_in,

$$z_i = \mathrm{SiLU}(r_{in} \cdot W^g_i) \cdot (r_{in} \cdot W^u_i)$$

y la contribución de la neurona es $m_i \cdot z_i \cdot W^d_i$. El coeficiente m_i vale 1 si la neurona está seleccionada y 0 si no, en el valor hacia delante. $\mathrm{SiLU}(t) = t \cdot \mathrm{sigmoide}(t)$. No hay sesgos en estas tres proyecciones.

Cada neurona posee un vector de afinidad G_i de dimensión g, un escalar b_i y una identidad estable ID_i. En el ejemplo g = 32 y la identidad es un entero de 64 bits, inicializado al índice de creación y almacenado aparte de ese índice. N es 8192, 16384 o 32768 en los ensayos. La cuota media de neuronas pesadas por capa es 1024 en los tres casos, de modo que la fracción activa del reservorio es 12,5 %, 6,25 % y 3,125 %.

Puntuación.

La figura 3 muestra el encaminador. En el modo medido la detección es directa y el predictor auxiliar de utilidad está apagado. Con el estado r:

$$q = \mathrm{normalizar}(W_q \cdot \mathrm{RMSNorm}_{\mathrm{encaminador}}(r))$$

$$A_i = q \cdot \mathrm{normalizar}(G_i)$$

$$s_i = A_i + \mathrm{recorte}(b_i, \pm 0{,}1)$$

W_q es una proyección aprendida de d a g, sin sesgo. Las normalizaciones de q y de G_i son de norma euclídea, con épsilon 1e−8. El producto A_i es un coseno. El recorte de la excitabilidad que entra en la puntuación es ±0,1 en las recetas medidas (el programa admite también ±0,5). La microactivación μ_i = sigmoide((A_i + b_i) / τ), con b_i sin recortar, solo se usa si se activa la intensidad opcional descrita más abajo; en el modo medido no multiplica la salida. La temperatura τ es 0,2. El cálculo de puntuaciones del ejemplo se hace en precisión de 32 bits, con la conversión automática a precisión reducida desactivada en esa región. Una puntuación no finita se rechaza antes de seleccionar.

El coste de esta puntuación es un producto de la consulta, de anchura g, por las N afinidades. Es distinto del producto pesado de anchura d de la neurona SwiGLU, y se calcula para las N neuronas.

Selección de cardinalidad exacta.

Para cada elemento, la capa dispone de una cuota entera K_l. En el modo de cuota uniforme, K_l es la cuota media. En el modo medido, un registro de presupuesto por elemento reparte un presupuesto B igual a la suma de las cuotas medias y concede a cada capa una cuota dentro de una banda, con la regla que se detalla más abajo. La selección usa esa cuota concedida.

Se ordenan las neuronas por puntuación decreciente y, a igualdad de puntuación, por identidad estable creciente. Se marcan las K_l primeras. No se suma a la puntuación ningún épsilon que dependa de la identidad ni ningún ruido: dos puntuaciones distintas conservan su orden, y el empate lo decide solo la identidad. La selección se hace sobre las N neuronas a la vez. El reservorio no se divide en bloques con un número fijo de neuronas activas por bloque, de modo que las K elegidas pueden concentrarse en cualquier zona del reservorio.

El ejemplo medido usa la realización por umbral, que admite una cuota distinta por elemento sin una sincronización de dispositivo a anfitrión. Sea B_sup una cota estática, en el ejemplo la cuota máxima de la banda. Se obtienen los B_sup mayores valores de la puntuación. El umbral del elemento es el valor situado en la posición K_l, contando desde el mayor. Toda neurona con puntuación estrictamente mayor que el umbral queda seleccionada. Las neuronas empatadas con el umbral se recorren en el orden canónico de identidad estable, y se toman las que hagan falta para completar K_l. Si K_l es 0, la máscara es vacía. La ordenación interna del operador de los K mayores solo aporta el valor umbral; su orden de empates no decide la máscara.

La otra realización, equivalente en el conjunto seleccionado, reordena las columnas al orden canónico de las identidades, ordena las puntuaciones de forma estable y

descendente, y dispersa la máscara de los K_l primeros rangos de vuelta al índice de almacenamiento. Sirve como referencia. El orden canónico se obtiene ordenando las identidades de forma estable, de modo que el resultado no depende del índice físico.

Ejecución del reservorio.

La figura 5 muestra dos ejecutores con el mismo valor hacia delante cuando la máscara es la máscara rígida.

El ejecutor denso enmascarado calcula z para las N neuronas, multiplica por la máscara y proyecta con los vectores de salida. Es el ejecutor de los ensayos de entrenamiento. No ahorra el producto pesado: el tiempo medido crece con N. En una GPU H100, en la actualización 288 y con 32768 elementos por actualización, el producto del reservorio fue una fracción pequeña del paso (del orden de 3 % a 4 %), y la selección sobre el producto elementos por N ocupó cerca de la mitad del paso hacia delante (418 ms de 867 ms con N = 8192; 797 ms con N = 16384; 1569 ms con N = 32768). Los caudales de entrenamiento en ese ejecutor fueron, aproximadamente, 22800, 13900 y 7500 elementos por segundo para N = 8192, 16384 y 32768.

El ejecutor por índices lee, para cada elemento, solo las filas W^g, W^u y W^d de las neuronas cuyo coeficiente es distinto de cero, calcula su SwiGLU y escribe la suma en la dimensión d. Una referencia de ese ejecutor está implementada y coincide en álgebra con el ejecutor enmascarado en las filas elegidas. No es el núcleo con el que se midió el caudal de entrenamiento. En inferencia de lote pequeño, el tráfico de pesos pesados por elemento y capa pasa de N vectores a K vectores. Con N = 65536 y K = 1024, esa razón es de 64. La selección, al depender de las afinidades de dimensión g y no de los tres vectores de dimensión d, puede resolverse antes de la lectura pesada y permite anticipar esas filas.

Registro de presupuesto del modo medido.

El presupuesto de un elemento es B, igual a L por la cuota media. Con L = 14 y cuota media 1024, B = 14336. La banda del ejemplo es ±25 %: cuota mínima 768 y cuota máxima 1280. Cada elemento lleva su saldo, inicializado a B si la posición es válida como entrada y a 0 si no lo es. En la capa l, con saldo R y n capas todavía posteriores, siendo n = L − l − 1:

inferior = max(cuota mínima, R − n · cuota máxima)

superior = min(cuota máxima, R − n · cuota mínima)

cuota concedida = recorte(petición, inferior, superior)

R pasa a ser R menos la cuota concedida

La petición del modo medido sale de la entropía normalizada de softmax(s / τ), comparada con su media móvil exponencial y su desviación en esa capa. El detalle de la petición, el tratamiento del relleno y la prueba del agotamiento exacto son la materia de la solicitud de reparto del mismo solicitante. Aquí basta el comportamiento usado en los ensayos: la suma de cuotas de un elemento válido es B, cada cuota cae en la banda, y, si al terminar la última capa algún saldo no es idénticamente cero, el programa interrumpe el entrenamiento antes del paso del optimizador, sin consolidar pesos ni medias móviles. Las posiciones que no pertenecen a la entrada válida, como el relleno, nacen con saldo 0 y reciben cuota 0 en cada capa, de modo que no consumen presupuesto. En el modo medido, una posición de un documento válido cuyo objetivo queda fuera de la pérdida recibe el presupuesto y lo gasta como las demás; excluirla también, con cuota 0 y saldo 0, es una variante descrita en la solicitud de reparto. Con la fracción de actividad fijada por la configuración, la cuota media no cambia a lo largo del entrenamiento. El registro de presupuesto sigue pudiendo dar a una capa entre 768 y 1280 neuronas según el elemento.

Ensanchar la banda a ±75 % de la cuota media no confirmó una mejora de entropía cruzada en tres semillas. La banda de ±25 % es la del modo medido, no un resultado de que la banda variable sea la causa del efecto de capacidad.

Entrenamiento de la máscara.

La figura 4 muestra el estimador. Sea m_rígida la máscara de la selección exacta. Sea s_sel la menor puntuación entre las neuronas seleccionadas y s_exc la mayor puntuación entre las excluidas. Si 0 < K_l < N, el umbral θ es (s_sel + s_exc) / 2 y se destaca del grafo de derivación. En los extremos K_l = 0 o K_l = N, θ vale 0 y la sigmoide se sustituye por el vector constante 0 o 1. La probabilidad sustituta es

p = sigmoide((s − θ) / τ)

y la máscara que entra en el producto es

m = m_rígida + p − destacado(p)

Hacia delante, m coincide con m_rígida. Hacia atrás, el gradiente respecto de las puntuaciones es el de p. La cuota K_l, por ser un entero producido por el selector y por el registro de presupuesto, no recibe gradiente. En evaluación e inferencia se usa solo m_rígida.

Una pérdida auxiliar de presupuesto, de peso 1e−3, es la media, sobre las posiciones que entran en la pérdida, de ((suma de p − K_l) / N) al cuadrado. No fija la cardinalidad: la cardinalidad exacta la impone m_rígida. El gradiente de los vectores W^g, W^u y

W^d de una neurona circula por los elementos en los que esa neurona está seleccionada. El gradiente de G, de W_q y de b circula por el estimador.

Inicialización.

Los pesos lineales y el embebido se inicializan con normal de media 0 y desviación 0,02. La semilla de cada tensor depende de la semilla del modelo y del nombre del parámetro, de modo que los tensores homólogos de dos anchuras reciben el mismo prefijo aleatorio. Las escalas de RMSNorm valen 1. La excitabilidad b empieza en 0. Las proyecciones residuales de la atención y las proyecciones de salida de todo SwiGLU, es decir, los vectores W^d del reservorio y la proyección descendente del perceptrón compartido, se dividen por la raíz cuadrada de 2L. Cada G_i se normaliza. Una inicialización alternativa, no usada en el modo medido, construye G por bloques ortogonales del tamaño g antes de normalizar. El optimizador es AdamW, con betas 0,9 y 0,95, épsilon 1e−8, decaimiento de peso 0,1 en los tensores de rango al menos 2 y decaimiento nulo en vectores y escalas, recorte de gradiente de norma 1, cálculo en BF16 y momentos y pesos maestros en FP32.

Receta y datos de los ensayos.

La campaña comparativa usó tasa de aprendizaje 1e−3, calentamiento lineal durante 5 millones de elementos, tasa constante después, lote de 32768 elementos, acumulado en sublotes de 16, 8 o 4 ventanas según la memoria. No hubo abandono. Una GPU por ejecución. La evaluación de desarrollo, cada 10 millones de elementos, usa 131072 elementos fijos que no entran en el entrenamiento.

El corpus del ejemplo es la Wikipedia inglesa wikimedia/wikipedia, configuración 20231101.en, revisión b04c8d1ceb2f5cd4588862100d08de323dccfbaa, deduplicada de forma exacta y por MinHash con Jaccard de al menos 0,9, partida por hash de documento en 98 % de entrenamiento, 1 % de desarrollo y 1 % reservado. Las ventanas tienen 1024 posiciones. El orden de documentos y de sublotes se fija de antemano y es común a todos los brazos, con semilla de datos 17. Las semillas de modelo 17, 29 y 43 se comparan emparejadas. El conjunto de entrenamiento grande de esa preparación tiene 548789581 elementos válidos. Los pesos obtenidos son experimentales.

Cuando la configuración no impone la fracción de actividad, el mismo programa aplica un calendario por escalones versionados: fracción 0,5 antes de 10 millones de elementos aceptados, 0,25 hasta 25 millones y 0,125 después, con bandas de ±25 % alrededor de la cuota media de cada tramo. Los ensayos comparativos de capacidad no usaron ese calendario: la fracción iba fijada de modo que la cuota media fuera 1024 desde el primer elemento.

Controles construidos con el mismo bloque.

La mezcla de expertos de control agrupa las filas del mismo SwiGLU en expertos de anchura 128. Con N_filas = 8192 hay 64 expertos; con 16384 hay 128; con 32768 hay 256. El encaminador de expertos es una proyección lineal del estado normalizado, seguida de softmax. Se seleccionan ocho expertos. Sus coeficientes se renormalizan para que sumen 8 y se repiten en las 128 filas del experto. La pérdida de equilibrio es el producto de la frecuencia de selección por la probabilidad media, multiplicado por el número de expertos, con peso 0,01. El perceptrón compartido, las normalizaciones y la atención son los del reservorio. Ocho expertos de anchura 128 ejecutan 1024 filas pesadas, la misma cuota media que el reservorio. La diferencia de granularidad es que las 128 filas de un experto se toman juntas, mientras cada neurona del reservorio se elige por su propia puntuación.

Un brazo denso de comparación sustituye el reservorio condicional por un SwiGLU denso de la anchura activa.

Resultados medidos.

Entropía cruzada de desarrollo en nats por elemento, a los 100 millones, tasa constante 1e−3, bloque con norma de entrada y post-norma, regulador apagado.

Modelo	**Totales / pesados activos**	**Semilla 17**	**Semilla 29**	**Semilla 43**
Denso de anchura activa	143M / 143M	3,928	—	—
Reservorio N = 8192	451,4M / 143,1M	3,874	3,868	3,865
Mezcla, 64 expertos	451,0M / 143,0M	3,878	3,874	3,845
Reservorio N = 16384	808,4M / 147,8M	3,832	3,828	3,834
Mezcla, 128 expertos	804,4M / 143,8M	3,880	3,874	3,881

La diferencia de unos 4 millones en la columna de activos entre el reservorio de 16384 y la mezcla de 128 expertos procede de las afinidades, que tocan las N neuronas con dimensión g. Las filas SwiGLU pesadas activas por elemento son 1024 en ambos.

Diferencias emparejadas por semilla, a los 100 millones:

– Reservorio 16384 menos reservorio 8192: −0,042, −0,040, −0,032. Media −0,038, desviación 0,005.

– Mezcla de 128 menos mezcla de 64: +0,002, 0,000, +0,036. Media +0,012.

– Reservorio 16384 menos mezcla de 128: −0,048, −0,046, −0,047. Media −0,047, desviación 0,001.

– Reservorio 8192 menos mezcla de 64: −0,004, −0,007, +0,020. Paridad a esa escala.

A los 200 millones, el reservorio de 16384 obtuvo 3,558, 3,552 y 3,554, y la mezcla de 128 obtuvo 3,587, 3,587 y 3,590. Diferencias −0,030, −0,035 y −0,037. En la semilla 17, el reservorio de 8192, la mezcla de 64 y el denso obtuvieron 3,593, 3,596 y 3,663. La diferencia entre reservorios de 16384 y 8192 en esa semilla fue −0,035.

A los 150 millones, dentro de la misma campaña, las diferencias entre el reservorio de 16384 y la mezcla de 128 fueron −0,036, −0,046 y −0,040.

Con totales cercanos a 1500 millones y 60 millones de elementos, el reservorio de 32768 frente a la mezcla de 256 expertos dio −0,045, −0,052 y −0,052. En ese mismo horizonte, el reservorio de 32768 frente al de 16384 dio +0,018, −0,020 y +0,002: la curva de capacidad, a 60 millones de elementos y con cuota media 1024, se satura entre 16384 y 32768. Subir la cuota media a 2048 o a 4096 no recuperó esa saturación en la semilla ensayada y empeoró el reservorio de 16384. La lectura que el solicitante extrae es que la duplicación de 8192 a 16384, con cuota media fija, es el régimen donde el efecto está confirmado en tres semillas y a 100–200 millones de elementos. La saturación posterior, a 60 millones de elementos, queda declarada.

Uso del encaminador de la mezcla de 128 expertos: utilización máxima entre el 40 % y el 48 % y mediana respecto de la uniforme entre 0,59 y 0,68. El resultado de esa mezcla no se explica por un colapso de su encaminador.

Varianza entre entornos y receta con enfriamiento de la tasa.

Repetido el par de igual total con tasa constante, en otro entorno de ejecución y la misma semilla 17, las entropías cruzadas a los 150 millones fueron 3,6512 y 3,6513. En la campaña anterior, la misma semilla y el mismo marco daban 3,644 y 3,680. La configuración resuelta y el código del modelo coincidían. La variación entre entornos, del orden de 0,02 a 0,03 nat, es mayor que la variación entre semillas dentro de una campaña. Las comparaciones emparejadas dentro de una campaña son las que sostienen las cifras de arriba. La magnitud de la diferencia a igualdad de totales debe leerse con esa reserva.

Un enfriamiento lineal de la tasa hasta el 10 % de su valor, durante el último 20 % de un entrenamiento de 150 millones de elementos, redujo la entropía cruzada en unos 0,17 nat en los dos brazos de una sola semilla (3,474 frente a 3,651 en el reservorio de 16384; 3,484 frente a 3,651 en la mezcla de 128). Con esa receta, la diferencia entre brazos fue −0,011 en esa semilla. Cambiar la tasa a 6e−4 o a 1,5e−3, retrasar el aprendizaje del encaminador, o cambiar el peso de la pérdida de equilibrio de la

mezcla, quedó dentro del ruido de una semilla. El enfriamiento es una receta de entrenamiento común a los dos brazos y mejora a los dos.

Comportamiento observado del selector.

Sin regulador de uso, las capas iniciales y medias concentran una parte de la cuota en neuronas seleccionadas en más del 90 % de los elementos. En el reservorio de 8192, la capa 2 mantuvo del orden de 400 neuronas en ese régimen, cerca del 39 % de la cuota, y la capa 3 llegó a unas 500, cerca del 49 %. Las capas finales encaminan de forma selectiva. Del orden de la mitad del reservorio de las capas 2 y 3 queda por debajo del 1 % de uso. A los 200 millones, en el reservorio de 16384, el uso máximo bajó al 80,8 %. El modelo forma por sí mismo una parte densa y una parte selectiva según la profundidad. Un regulador que penaliza por igual el uso alto y el uso bajo destruye esa parte densa y empeora la predicción: con pre-normalización y 100 millones de elementos, el regulador proporcional obtuvo 4,019 y 4,154 en dos semillas, el regulador integral 4,023 y 4,032, y la ausencia de regulador 3,966 y 3,961.

El regulador, cuando se enciende, mantiene una media móvil del uso con semivida de 1 millón de elementos, α = 1 − 2^(−elementos / semivida). Con fracción r = K / N, la banda por defecto va de 0,1·r a min(0,95, 1,5·r). Fuera de la banda, la corrección es el logaritmo del uso respecto de la frontera, recortado a ±2, y se resta de la puntuación con un coeficiente (0,5 en los ensayos del regulador). Una variante de rescate usa frontera inferior 0,5·r y deja la frontera superior en el tope 0,95, de modo que las neuronas casi siempre activas no reciben penalización. El modo medido de la invención lleva el regulador apagado. No se reivindica un beneficio del regulador.

Otras variantes implementadas, sin efecto confirmado.

Puede añadirse a la puntuación, con coeficiente, un predictor de utilidad de rango bajo. El predictor del ejemplo calcula v = tanh(W_z · RMSNorm(r)) de rango 8, una predicción por neurona mediante la función softplus, log(1 + e^t), y una puntuación típica recortada a ±3 a partir de medias móviles. Se entrena con pérdida de Huber contra |z_i| · norma de W^d_i / raíz de d, en 64 neuronas seleccionadas y 64 no seleccionadas, una posición válida por capa cada 32 actualizaciones. En el modo medido está apagado.

La intensidad opcional multiplica la salida de la neurona seleccionada por μ_i, bien renormalizada entre las seleccionadas para conservar la cuota, bien con un suelo. No forma parte del modo medido.

La consulta puede sumar una proyección de un resumen, destacado del grafo, de las afinidades seleccionadas en la capa anterior. Es una variante implementada, no el modo medido.

La temperatura puede ser un parámetro aprendido, limitado de modo que τ permanezca entre 0,02 y 5.

Alcance de los ensayos.

Los ensayos cubren una profundidad y una anchura (14 capas, d = 1024), totales de 451 millones, 808 millones y 1522 millones de parámetros, y de 60 a 200 millones de elementos de entrenamiento, más un barrido de receta a 150 millones en una semilla. El corpus y el conjunto de desarrollo son únicos. No hay batería de tareas posteriores ni ajuste por instrucciones. El ejecutor de entrenamiento es el denso enmascarado. La ventaja de tráfico de la inferencia por índices es algebraica y de la referencia implementada, no un caudal medido en producción. La diferencia a igualdad de totales depende del entorno de ejecución en la cuantía ya dicha. Nada en estos ensayos afirma un comportamiento a miles de millones de elementos ni frente a toda mezcla de expertos publicada.

Aplicación industrial

La capa se fabrica como programa ejecutado por un procesador, una GPU u otro acelerador, y como parte de un sistema de procesamiento de datos con memoria y uno o más procesadores. Se usa para entrenar y para ejecutar modelos que predicen el elemento siguiente de una secuencia, en particular texto, y para cualquier otra secuencia de vectores en la que convenga aumentar la capacidad parametrizada manteniendo el número de neuronas pesadas activas. El sistema resultante presta un servicio industrial de inferencia y de entrenamiento.

Lista de signos de referencia

10 red neuronal. 12 capa. 14 embebido y proyección de salida. 20 normalización de la atención. 22 atención. 24 estado residual r. 30 normalización del perceptrón compartido. 32 perceptrón compartido. 34 salida F del perceptrón compartido. 40 normalización de entrada del reservorio. 42 reservorio. 44 neurona. 46 vectores de puerta, ascenso y salida de la neurona. 48 vector de afinidad. 50 excitabilidad basal. 52 identidad estable. 60 normalización del encaminador. 62 proyección de consulta. 64 consulta normalizada. 66 puntuaciones. 70 selector de cardinalidad exacta. 72 máscara rígida. 80 contribución D del reservorio. 82 suma de F y D. 84 normalización posterior. 86 salida de la capa. 90 umbral destacado del estimador. 92 sigmoide sustituta. 94 ejecutor denso enmascarado. 96 ejecutor por índices.