REIVINDICACIONES

1. Método implementado por ordenador para calcular una representación de salida de una capa (12) de una red neuronal (10) a partir de una representación de entrada de un elemento de una secuencia, en el que la capa dispone de varias unidades de transformación y usa un subconjunto de ellas para dicho elemento, caracterizado por:

- la capa comprende un reservorio (42) de N unidades (44), con N entero mayor que 1, y cada unidad calcula una activación SwiGLU z_i = SiLU(r_in · W^g_i) · (r_in · W^u_i) mediante vectores propios de puerta y de ascenso, y puede contribuir a la salida con z_i · W^d_i, siendo W^d_i un vector de salida propio de la unidad;
- cada unidad tiene un vector de afinidad (48) propio, de dimensión g menor que la dimensión d de la representación, distinto de los vectores de puerta, de ascenso y de salida de la unidad y no formado por subclaves compartidas con otras unidades, un escalar de excitabilidad basal (50) y una identidad estable (52) distinta del índice con el que la unidad está almacenada;
- se obtiene, para el elemento, un vector de consulta (64) normalizado mediante una proyección aprendida del estado residual (24) de la capa, y una puntuación de cada una de las N unidades, igual al producto escalar de la consulta normalizada por el vector de afinidad normalizado, más la excitabilidad basal limitada a un intervalo acotado, calculándose la puntuación de las N unidades;
- se seleccionan exactamente K unidades de entre las N unidades del reservorio, siendo K un entero que cumple 0 < K < N, sin limitar a una cantidad predeterminada el número de unidades seleccionadas dentro de ningún subconjunto del reservorio, según el orden lexicográfico de puntuación decreciente e identidad estable creciente, permaneciendo las puntuaciones intactas, sin ruido añadido;
- se forma una contribución (80) del reservorio como suma, sobre las unidades seleccionadas, de z_i · W^d_i, con una máscara rígida (72) que en el valor hacia delante vale uno en cada unidad seleccionada y cero en cada unidad no seleccionada; y
- la representación de salida (86) de la capa combina el estado residual con dicha contribución.

2. Método según la reivindicación 1, caracterizado por que la capa calcula además la salida (34) de un perceptrón compartido (32), activo para todo elemento e independiente de la selección, de anchura menor que K; por que la entrada r_in del

reservorio es una normalización cuadrática media del estado residual; y por que la salida de la capa es el estado residual más una normalización cuadrática media de la suma de la salida del perceptrón compartido y de la contribución del reservorio.

3. Método según la reivindicación 2, caracterizado por que la anchura del perceptrón compartido es a lo sumo la octava parte de la cuota media de unidades seleccionadas por capa.

4. Método según la reivindicación 1 o 2, caracterizado por que la razón entre N y la cuota media de unidades seleccionadas por capa es al menos 8.

5. Método según la reivindicación 4, caracterizado por que dicha razón es al menos 16.

6. Método según la reivindicación 1, caracterizado por que la selección de las K unidades comprende obtener un umbral igual al K-ésimo mayor valor de puntuación, marcar toda unidad de puntuación estrictamente mayor que el umbral, y completar la cardinalidad K con unidades de puntuación igual al umbral recorridas en orden de identidad estable creciente, usando una cota estática del número de valores recuperados para que la cuota propia de cada elemento no exija una sincronización con el procesador anfitrión.

7. Método según la reivindicación 1, caracterizado por que la selección comprende reordenar las unidades a un orden canónico de sus identidades estables, ordenar las puntuaciones de forma estable y descendente, y marcar las K primeras posiciones de esa ordenación.

8. Método según la reivindicación 1, caracterizado por que, en inferencia, el producto de puerta, el producto de ascenso y el producto de salida de una unidad se leen de la memoria solo si la unidad está seleccionada para ese elemento.

9. Método según la reivindicación 8, caracterizado por que la selección de las K unidades se resuelve a partir de las puntuaciones, calculadas con los vectores de afinidad de dimensión g, antes de leer de la memoria los vectores de puerta, de ascenso y de salida, y por que la lectura se limita a las filas de las unidades seleccionadas.

10. Método de entrenamiento de una red neuronal que ejecuta el método de una cualquiera de las reivindicaciones 1 a 7, caracterizado por que, durante el entrenamiento, la máscara que multiplica la activación de cada unidad es la máscara rígida más una sigmoide sustituta menos el valor destacado de esa sigmoide, de modo que el valor hacia delante es la máscara rígida y el gradiente respecto de las puntuaciones es el de la sigmoide; por que el centro de la sigmoide es el punto medio, destacado del grafo de derivación, entre la menor puntuación de las unidades

seleccionadas y la mayor puntuación de las unidades no seleccionadas cuando la cuota está estrictamente entre 0 y N; y por que la cuota entera K no recibe gradiente.

11. Método según la reivindicación 10, caracterizado por que se añade a la pérdida una media, sobre los elementos que contribuyen a la pérdida principal, del cuadrado de (suma de los valores de la sigmoide sustituta − K) / N, con un peso que no sustituye a la máscara rígida como definición de la cardinalidad.

12. Método según la reivindicación 10, caracterizado por que la capa presenta además las características de la reivindicación 2 y la razón entre N y la cuota media de unidades seleccionadas por capa es al menos 8.

13. Método según la reivindicación 1, caracterizado por que un mismo elemento posee un presupuesto entero B repartido entre L capas, y la cuota de la capa se obtiene recortando una petición entera al intervalo cuyo extremo inferior es el máximo entre una cuota mínima y el saldo menos el producto del número de capas posteriores por una cuota máxima, y cuyo extremo superior es el mínimo entre la cuota máxima y el saldo menos el producto del número de capas posteriores por la cuota mínima, restándose la cuota concedida del saldo de ese elemento.

14. Método según la reivindicación 1, caracterizado por que la red comprende una pila de dichas capas en un descodificador, con atención causal limitada al mismo documento, y el entrenamiento minimiza la entropía cruzada de la predicción del elemento siguiente.

15. Sistema de procesamiento de datos que comprende memoria y al menos un procesador, caracterizado por que está configurado para ejecutar el método de una cualquiera de las reivindicaciones 1 a 14.

16. Programa de ordenador que comprende instrucciones que, al ser ejecutadas por un ordenador, hacen que el ordenador ejecute el método de una cualquiera de las reivindicaciones 1 a 14.

17. Soporte de almacenamiento legible por ordenador, caracterizado por que almacena el programa de ordenador de la reivindicación 16.