DESCRIPCIÓN

Título de la invención

Método y sistema de reparto de un presupuesto de cómputo por elemento entre capas de una red neuronal.

Sector de la técnica

La invención pertenece a la asignación de recursos de cómputo en un sistema de procesamiento de datos que ejecuta una red neuronal de varias capas. Cada capa consume, para cada elemento de una secuencia, un número entero de unidades de cálculo condicional. La invención reparte un presupuesto fijo de ese elemento entre las capas.

Clasificación internacional sugerida: G06F 9/50 (asignación de recursos) y G06N 3/04 (arquitecturas de redes neuronales).

Estado de la técnica anterior conocido por el solicitante

En una mezcla de expertos, cada capa elige un número fijo de expertos por elemento. Shazeer y otros, arXiv:1701.06538, 2017; Lepikhin y otros, arXiv:2006.16668, 2020; Fedus, Zoph y Shazeer, arXiv:2101.03961, 2021; y Dai y otros, arXiv:2401.06066, 2024, describen esa elección por capa. La cuota de una capa no depende del saldo que las capas posteriores todavía tienen que recibir, ni existe un presupuesto único del elemento que deba agotarse de forma exacta al terminar la pila.

Zhou y otros, «Mixture-of-Experts with Expert Choice Routing», arXiv:2202.09368, 18 de febrero de 2022, dejan que cada experto elija sus elementos, de modo que un elemento recibe un número variable de expertos. Huang y otros, «Harder Tasks Need More Experts: Dynamic Routing in MoE Models», arXiv:2403.07652, 12 de marzo de 2024, deciden cuántos expertos activa cada elemento según la confianza del encaminador. En los dos casos el número de unidades de un elemento varía capa a capa sin un presupuesto del elemento que viaje entre las capas, se agote de forma exacta y reserve el mínimo de las capas posteriores.

Graves, «Adaptive Computation Time for Recurrent Neural Networks», arXiv:1603.08983, 2016, acumula probabilidades de parada en cada paso hasta alcanzar $1 - \varepsilon$ y asigna al último paso el resto, de modo que la suma es exactamente uno, con un número máximo de pasos. El procedimiento es continuo. No hay cuota mínima por paso ni una cota inferior que obligue a gastar para que el resto sea absorbible. La patente US 10740433 B2, de Google, «Universal transformers», aplica ese mecanismo de parada a cada posición con un número máximo de pasos.

Liu y otros, «Alloc-MoE», arXiv:2604.08133, 9 de abril de 2026, reparten entre las capas de una mezcla de expertos un total fijo de activaciones de expertos por elemento. Resuelven el reparto fuera de línea, por programación dinámica, con cada capa entre 1 y el número original de expertos, y lo aplican igual a todos los elementos. Zasada y otros, «SoftMoE: Soft Differentiable Routing for MoE in LLMs», arXiv:2606.17952, 16 de junio de 2026, parametrizan el número medio de expertos activos por capa e imponen que la suma sobre las capas sea igual a un presupuesto global. El presupuesto es una media sobre los elementos, no el trabajo de cada elemento. Yue y otros, «Ada-K Routing», ICLR 2025, arXiv:2410.10456, deciden en cada capa, con un asignador entrenado por refuerzo, cuántos expertos recibe cada elemento, y penalizan el número esperado sin presupuesto estricto. Cai y otros, «GeMoE», arXiv:2606.26287, 24 de junio de 2026, predicen por elemento un número de expertos redondeado y recortado a una banda, creciente con la entropía de la puerta, sin presupuesto repartido entre capas. «AdaMoE», arXiv:2406.13233, 2024, y «MoE++», arXiv:2410.07348, 2024, conservan la forma fija de la selección de los k mayores añadiendo expertos nulos o de cómputo cero.

En ninguno de esos documentos cada elemento lleva un saldo entero que pasa de capa en capa, cuya concesión en cada capa esté acotada a la vez por la banda propia y por lo que las capas posteriores pueden absorber, de modo que el presupuesto de ese elemento se agote de forma exacta en la última capa, cualquiera que sea la petición.

Raposo y otros, «Mixture-of-Depths», arXiv:2404.02258, 2024, reparten cómputo permitiendo que un elemento no atraviese alguna capa. El mecanismo decide una omisión. No reparte un presupuesto entero positivo que todas las capas deben poder gastar dentro de una banda, ni impide que una capa temprana deje a las posteriores por debajo de un mínimo o por encima de un máximo.

He, arXiv:2407.04153, 2024, recupera un número de expertos de una neurona dentro de una capa. El presupuesto no viaja de capa en capa con un saldo por elemento.

Cuando la cuota puede variar por capa y por elemento, un reparto ingenuo falla de dos maneras. Si una capa gasta demasiado, el saldo no alcanza para dar a cada capa posterior su cuota mínima. Si una capa gasta demasiado poco, el saldo que queda supera lo que las capas posteriores pueden absorber sin pasar de su cuota máxima, y el presupuesto no se agota. Promediar la cuota en el lote no fija el trabajo de un elemento concreto. Contar el relleno como trabajo desplaza el presupuesto científico hacia posiciones que no entran en la pérdida.

Problema técnico

Hace falta un procedimiento, ejecutable por un procesador para cada elemento por separado, que conceda a cada capa una cuota entera de unidades de cálculo dentro de una banda [K_min, K_max], que impida a una capa dejar a las posteriores fuera de esa banda, y que agote un presupuesto B exactamente cuando se cumplen las condiciones de consistencia L · K_min ≤ B ≤ L · K_max. El procedimiento tiene que ser determinista, local en el saldo del elemento, y no debe gastar presupuesto en posiciones que el entrenamiento excluye de la pérdida.

Explicación de la invención

La invención es un método implementado por ordenador, el sistema que lo ejecuta y el programa correspondiente.

Cada elemento válido de la secuencia lleva un saldo entero, inicializado al presupuesto B. Las capas se recorren en el orden de la red. En la capa corriente, con saldo R y con n capas todavía posteriores, el procesador calcula

inferior = max(K_min, R − n · K_max)

superior = min(K_max, R − n · K_min)

cuota = recorte(petición, inferior, superior)

y sustituye el saldo por R − cuota. La petición es un entero propio de la capa y del elemento. Puede ser constante e igual a la cuota media. En el modo preferente se obtiene de una señal de demanda de la propia capa, en particular de la entropía de sus puntuaciones de encaminamiento comparada con una media móvil.

La construcción de los extremos produce tres propiedades, que un experto comprueba por inducción sobre las capas siempre que K_min y K_max sean enteros, 0 ≤ K_min ≤ K_max, y L · K_min ≤ B ≤ L · K_max.

La cuota concedida cae dentro de [K_min, K_max]. El saldo que queda permite a cada capa posterior recibir al menos K_min y a lo sumo K_max, sea cual sea la petición, porque el extremo inferior obliga a gastar lo bastante para que el resto quepa bajo los máximos posteriores, y el extremo superior impide gastar lo que dejaría a las posteriores por debajo de su mínimo. En la última capa, n = 0, de modo que inferior = max(K_min, R) y superior = min(K_max, R). El saldo que llega a la última capa está dentro de la banda, luego inferior = superior = R, la cuota es R y el saldo final es 0. La suma de las cuotas del elemento es B.

Una posición que no pertenece a la entrada válida, como el relleno, no recibe este presupuesto: su saldo se mantiene en 0 y su cuota en 0. En una variante, tampoco lo

recibe una posición de la entrada válida cuyo objetivo queda excluido de la pérdida. Si al terminar la pila algún saldo no es cero, el paso de entrenamiento no se consolida: esa comprobación detecta una realización que hubiera violado el agotamiento.

El efecto técnico es de control del procesador. El número de unidades condicionales ejecutadas para un elemento queda fijado de antemano, acotado por capa, agotado al final de la pila y separado del relleno. Como ninguna capa puede recibir más de K_max, el procesador reserva para cada capa tensores de forma fija dimensionados por K_max. La selección de las unidades de cada elemento, aunque su cuota varíe, se resuelve con esa cota estática, sin leer las cuotas en el procesador anfitrión ni sincronizar el acelerador con él. El trabajo total de un lote queda determinado por B y por el número de posiciones válidas antes de ejecutar la pila, lo que permite planificar memoria y tiempo. No se afirma, porque los ensayos no lo confirman, que ensanchar la banda mejore la entropía cruzada de la predicción. Frente al reparto estático entre capas, el procedimiento es en línea y propio de cada elemento: la petición puede cambiar de un elemento a otro según su contenido sin que ninguno salga del presupuesto. Frente al presupuesto medio, garantiza el gasto de cada elemento y no solo la media del lote, sin pérdida de penalización. Frente a la parada adaptativa, impone además un mínimo por capa, y el extremo inferior obliga a gastar en una capa lo que las posteriores no podrían absorber.

Ventajas

El presupuesto es por elemento y no una media del lote, de modo que el trabajo de cada posición es el que el saldo describe. La cota K_max es estática: la memoria de trabajo de la capa más cargada y la forma de los tensores de selección se conocen antes de ejecutar la red. Ninguna capa puede agotar el mínimo de las que la siguen ni dejar un resto que esas capas no puedan absorber. El agotamiento es exacto y comprobable al terminar la pila. La misma regla sirve para un reservorio de neuronas con selección de cardinalidad K y para una mezcla de expertos cuya cuota es un número de expertos. La petición puede ser constante, y entonces la regla devuelve la cuota media en todas las capas, o puede variar dentro de la banda sin perder las tres propiedades.

Breve descripción de los dibujos

La figura 1 muestra el presupuesto de un elemento recorriendo la pila de capas.

La figura 2 muestra el recorte de la petición entre el extremo inferior y el extremo superior, y es la figura característica para el resumen.

La figura 3 muestra la formación de la petición a partir de la entropía de las puntuaciones.

Exposición detallada de un modo de realización

Regla de concesión.

La figura 1 muestra una pila (10) de L capas (20). Un elemento (12) entra con el presupuesto (14) B. El saldo (16) viaja de capa en capa. La figura 2 detalla el concesor (24) de una capa: recibe la petición (22), el saldo (16), el número n de capas posteriores, K_min (26) y K_max (28), y emite la cuota (30).

En el ejemplo numérico de comprobación, L = 3, K_min = 2, K_max = 4 y B = 9. Se cumple $3 \cdot 2 \le 9 \le 3 \cdot 4$.

Capa 1, n = 2, petición = 4, saldo = 9. El extremo inferior es max(2, 9 − 8) = 2. El extremo superior es min(4, 9 − 4) = 4. La cuota es 4. El saldo pasa a 5.

Capa 2, n = 1, petición = 1, saldo = 5. El extremo inferior es max(2, 5 − 4) = 2. El extremo superior es min(4, 5 − 2) = 3. La petición 1 se eleva a 2. El saldo pasa a 3. La elevación es lo que impide dejar a la última capa un resto superior a K_max.

Capa 3, n = 0, petición = 4, saldo = 3. El extremo inferior es max(2, 3) = 3. El extremo superior es min(4, 3) = 3. La cuota es 3. El saldo final es 0. La suma de cuotas es 9.

Si la petición de la capa 1 fuera mayor que 4, el concesor la recortaría a 4. Si la petición de la capa 1 fuera 0, el concesor la elevaría al extremo inferior. La petición no puede sacar la cuota de la banda ni romper el agotamiento.

Presupuesto del ejemplo medido.

En la red de 14 capas usada por el solicitante, la cuota media K_med es 1024, B = 14336, la fracción de banda es 0,25, K_min = 768 y K_max = 1280. Se cumple $14 \cdot 768 = 10752 \le 14336 \le 17920 = 14 \cdot 1280$. Cada elemento válido se inicializa con saldo 14336. Si, tras la última capa, algún saldo es distinto de cero, el programa interrumpe el entrenamiento antes de calcular el gradiente y antes del paso del optimizador, de modo que no se consolida nada.

La cuota media procede de una fracción de actividad configurada. Con fracción 0,125 y un reservorio de 8192 unidades, con fracción 0,0625 y 16384 unidades, o con fracción 0,03125 y 32768 unidades, K_med vale 1024. La banda se recalcula como K_med más o menos la parte entera de K_med por la fracción de banda, con la cuota mínima al menos 1 y la máxima a lo sumo el tamaño del reservorio. Un modo alternativo, implementado y no usado en los ensayos comparativos de capacidad, cambia la fracción por escalones versionados: 0,5 hasta 10 millones de elementos

aceptados, 0,25 hasta 25 millones y 0,125 en adelante. Al cambiar la fracción cambian K_med, la banda y B, y la regla de concesión se aplica con los nuevos enteros. No se interpola B dentro de una actualización.

Petición por entropía.

La figura 3 muestra el estimador (40). La capa dispone de puntuaciones s_i de sus unidades o de sus expertos. Con temperatura τ = 0,2 en el ejemplo,

p = softmax(s / τ)

H = − (suma de p_i · log p_i) / log(N)

donde N es el número de puntuaciones y el logaritmo del denominador está acotado inferiormente para evitar la división por cero. H cae entre 0 y 1. La capa guarda una media móvil E[H] y un segundo momento E[H²], actualizados al consolidar una actualización aceptada, con el mismo factor exponencial que una semivida de 1 millón de elementos: α = 1 − 2^(−elementos_válidos / 10^6). La desviación usada en la petición es la raíz de max(E[H²] − E[H]², 0), con suelo 0,01. La señal

u = recorte((H − E[H]) / desviación , −1, 1)

vale 0 mientras la capa no ha consolidado ninguna actualización. La petición es el entero más cercano a K_med + Δ · u, con Δ = parte entera de K_med · 0,25. Así, u = 1 pide K_max, u = −1 pide K_min y u = 0 pide K_med, en el ejemplo 1280, 768 y 1024. H se destaca del grafo de derivación antes de formar u: la petición no recibe gradiente. Si el reparto variable está desactivado en la configuración, u se fuerza a 0 y la petición es K_med; la regla de concesión sigue aplicándose y, con petición constante dentro de la banda y saldo inicial B = L · K_med, cada capa recibe K_med.

La entropía es una heurística de demanda. No se afirma que mida la dificultad del elemento. Los ensayos con fracción de banda 0,75, en tres semillas, no confirmaron una reducción de la entropía cruzada frente a la banda 0,25. La banda 0,50 resultó neutra en el cribado. La invención se apoya en el invariante de concesión, que se cumple con cualquier petición, incluida la petición constante.

Posiciones que no gastan.

El elemento que no pertenece a un documento de entrada nace con saldo 0 y recibe, en cada capa, cuota 0 y saldo de salida 0. De ese modo el relleno no acumula un saldo que las capas posteriores interpretarían como trabajo pendiente, y la comprobación de saldo final cero sigue siendo válida. En el ejemplo medido, una posición de un documento válido cuyo objetivo queda fuera de la pérdida, por ejemplo la parte de una ventana ya consumida en una actualización anterior, recibe el presupuesto B y lo gasta

como las demás. Así su representación sigue sirviendo de contexto a las posiciones posteriores del mismo documento. En una variante, esas posiciones reciben también saldo 0 y cuota 0, y su representación pasa por la capa sin contribución condicional. La variante ahorra cómputo cuando la parte excluida de la pérdida es grande, a cambio de ese contexto.

Realización sobre un reservorio de neuronas.

Cada capa contiene N neuronas direccionables. La cuota concedida es el número de neuronas que el selector de cardinalidad exacta marca para ese elemento. El selector, las afinidades y la máscara rígida pueden ser los de la solicitud de capa del mismo solicitante, o cualquier selector que acepte una cuota entera por elemento. El concesor no necesita conocer los pesos de las neuronas: solo la petición, el saldo y las bandas. En el ejemplo, la petición sale de las puntuaciones de afinidad de las N neuronas. El producto pesado de las neuronas usa después la cuota concedida. El selector del ejemplo recupera, para cada elemento, los K_max mayores valores de puntuación, cota estática igual para todos los elementos, toma como umbral el valor situado en la posición de la cuota concedida y completa los empates por identidad estable. Así, cuotas distintas por elemento no exigen formas de tensor distintas ni una lectura de las cuotas en el procesador anfitrión.

Realización sobre una mezcla de expertos.

Cada capa contiene E expertos. K_min y K_max se expresan en número de expertos, y B es la suma de las cuotas medias de expertos. La misma regla concede cuántos expertos se activan en cada capa para ese elemento. La petición puede salir de la entropía del softmax de los logits del encaminador de expertos. Esta realización muestra que el reparto no está ligado a la granularidad de neurona. El control experimental del solicitante usó, en la mezcla, una cuota fija por capa igual a la fracción por el número de expertos, sin aplicar la banda variable; la regla aquí descrita cubre también ese caso al fijar la petición en la cuota media.

Comprobación y consolidación.

Tras la última capa, el procesador lee el saldo de todos los elementos del lote. Si alguno es distinto de cero, la actualización no se consolida: no hay paso del optimizador ni actualización de las medias móviles. En el ejemplo, el programa interrumpe además el entrenamiento y lo señala como error. El fallo indica una banda inconsistente, un desbordamiento o una máscara de validez mal aplicada. Con las hipótesis de la inducción, el fallo no se produce. La comprobación es una salvaguarda de la realización, no un sustituto de la regla.

Lo que los ensayos no atribuyen a la banda.

El solicitante midió la calidad de predicción de una red que usa esta regla con fracción de banda 0,25. Esa red es el modo de realización del reservorio, no un experimento que aísle la banda. El cribado que sí cambia la banda, de 0,25 a 0,75, dio diferencias de entropía cruzada de −0,031, −0,003 y +0,037 nat en tres semillas a los 60–100 millones de elementos, sin el mismo sentido ni el umbral de 0,02 nat que el solicitante había fijado para dar por confirmado un efecto. Por eso las reivindicaciones no piden protección sobre una mejora de predicción debida a la variación de la cuota. Piden protección sobre el procedimiento que impone el presupuesto, las bandas y el agotamiento.

Aplicación industrial

El método se ejecuta en el entrenamiento y en la inferencia de redes neuronales en procesadores, GPU y otros aceleradores, siempre que una pila de capas consuma por elemento un número entero de unidades condicionales. Fija de antemano el trabajo por elemento, permite dimensionar memoria y tiempo de la capa más cargada mediante K_max, y deja el trabajo del relleno en cero. Es un control de recursos de un sistema de procesamiento de datos.

Lista de signos de referencia

10 pila de capas. 12 elemento de la secuencia. 14 presupuesto B. 16 saldo R. 20 capa. 22 petición. 24 concesor. 26 cuota mínima. 28 cuota máxima. 30 cuota concedida. 40 estimador de entropía. 42 media móvil de la entropía. 44 señal u. 50 máscara de posiciones válidas.