DESCRIPCIÓN

Título de la invención

Método de rescate por división de unidades infrautilizadas en un reservorio de unidades direccionables de una red neuronal.

Sector de la técnica

La invención pertenece al procesamiento de datos mediante redes neuronales cuya capa condicional selecciona, para cada elemento de una secuencia, un número exacto de unidades de un reservorio por medio de una clave de afinidad propia de cada unidad. Concierne al reparto de la carga de selección entre las unidades durante el entrenamiento: cómo devolver al aprendizaje las unidades que el selector ha dejado de elegir, sin perturbar la función que la capa calcula ni el reparto de las unidades que sí se usan.

Clasificación internacional sugerida: G06N 3/08 (métodos de aprendizaje), G06N 3/082 (adaptación de la estructura de la red) y G06N 3/0495 (redes con activación dispersa o condicional).

Estado de la técnica anterior conocido por el solicitante

En las capas de cálculo condicional, sean mezclas de expertos o reservorios de unidades direccionables, la selección de un subconjunto de unidades por elemento tiende a concentrarse: las unidades elegidas al principio reciben gradiente, mejoran y son elegidas más; las que no se eligen no reciben gradiente y dejan de ser elegidas. Las mezclas de expertos corrigen esa concentración con una pérdida auxiliar de equilibrio por experto (Fedus, Zoph y Shazeer, «Switch Transformers», arXiv:2101.03961, 2021), con un sesgo por experto ajustado sin pérdida (Wang y otros, arXiv:2408.15664, 2024) o con un término sobre los logaritmos del encaminador. Esas técnicas actúan sobre la puntuación de la unidad a través del encaminador y son eficaces con decenas o centenas de expertos de gran anchura; el solicitante ha medido que, aplicadas como sesgo homeostático a un reservorio de miles de unidades de una neurona, la corrección simétrica empeora la calidad y la corrección asimétrica, solo de rescate por sesgo, es neutra.

Sokar y otros, «The Dormant Neuron Phenomenon in Deep Reinforcement Learning», ICML 2023, arXiv:2302.12902, detectan neuronas de activación casi nula y las reciclan: reinicializan sus pesos de entrada con la distribución de inicialización original y ponen a cero sus pesos de salida. Dohare y otros, «Loss of plasticity in deep continual learning», Nature, vol. 632, págs. 768–774, 2024 (versión previa: «Maintaining Plasticity in Deep Continual Learning», arXiv:2306.13812, 2023),

reinicializan de forma continua una fracción pequeña de las unidades de menor utilidad, con pesos de entrada aleatorios, pesos de salida a cero y un umbral de madurez. En ambos casos la capa es densa: la unidad reiniciada participa en el cálculo de todos los elementos desde el instante de la reinicialización, y su entrada aleatoria significa que empieza a aprender desde cero, sin relación con lo que la red ya sabe.

Chen, Goodfellow y Shlens, «Net2Net», arXiv:1511.05641, 2015, ensanchan una capa densa dividiendo una unidad en dos copias idénticas y repartiendo entre ellas, por mitades, los pesos de salida, de modo que la función de la capa se conserva exactamente. Esa división altera la unidad original y necesita que las dos copias participen siempre juntas en el cálculo, lo que un selector de cardinalidad exacta no garantiza.

Bricken y otros, «Towards Monosemanticity: Decomposing Language Models With Dictionary Learning», Transformer Circuits Thread, 2023, y Gao y otros, «Scaling and evaluating sparse autoencoders», arXiv:2406.04093, 2024, tratan las latentes muertas de un autoencoder disperso: las remuestrean en dirección a entradas de pérdida alta, o añaden una pérdida auxiliar que las obliga a explicar el residuo. Un autoencoder disperso no tiene selector por afinidad ni cuota exacta por elemento, y el remuestreo hacia entradas concretas no es una copia de otra unidad.

Las mezclas de expertos que crecen duplican expertos enteros: Dwivedi y otros, «Expert Upcycling», arXiv:2604.19835, 2026, copian un experto con su fila del encaminador y añaden ruido al sesgo; Guo y otros, «DynMoE», arXiv:2405.14297, 2024, añaden un experto inicializado para que lo elijan los elementos que no activaban ninguno. Esas operaciones cambian el número de expertos y la anchura del encaminador; no reutilizan una unidad existente e infrautilizada, y la copia entera de un experto con su salida altera el reparto en cuanto el encaminador puede elegirla.

He, arXiv:2407.04153, 2024 (PEER; WO 2025/217570 A1), y los documentos citados en la solicitud del mismo solicitante sobre la capa de reservorio describen selectores de cardinalidad exacta sobre reservorios grandes de expertos de una neurona con claves. Ninguno describe qué hacer con las unidades que el selector deja de elegir.

En un reservorio de unidades direccionables por afinidad, una unidad infrautilizada tiene una clave que ningún elemento consulta con puntuación suficiente. Reinicializarla al azar no la acerca a ninguna región de consulta; en un reservorio de miles de unidades, una clave aleatoria queda con gran probabilidad tan lejos de las consultas como estaba. Copiar la unidad más usada con su proyección de salida duplicaría su contribución en los elementos en que ambas fueran seleccionadas. Y en un selector de cardinalidad exacta, la unidad rescatada, cuando entra en las K plazas,

desplaza a la unidad marginal, de modo que la función de la capa cambia aunque la contribución nueva sea nula. Hace falta un procedimiento que lleve la unidad infrautilizada a una región de consulta activa, sin duplicar contribuciones, con un cambio de función acotado a la unidad marginal desplazada, y que sea reproducible en una cadena de entrenamiento con puntos de control y retomadas.

Problema técnico

Hace falta un método para devolver al aprendizaje, durante el entrenamiento, las unidades de un reservorio direccionable que el selector de cardinalidad exacta ha dejado de elegir, de manera que:

- la unidad rescatada sea seleccionada de nuevo en elementos reales, en la región de consulta de una unidad que sí trabaja, y reciba gradiente desde la primera actualización posterior;
- la contribución de la unidad rescatada a la salida sea nula en el instante del rescate, y la unidad donante no cambie, de modo que el cambio de la función de la capa quede acotado a la unidad marginal desplazada;
- el estimador de uso que decide qué unidades están infrautilizadas no vuelva a señalar de inmediato a la unidad rescatada ni a la donante;
- la operación ocurra en instantes exactos y reproducibles de la cadena de entrenamiento, quede registrada y se repita idénticamente si el entrenamiento se retoma desde un punto de control anterior; y
- la operación no se ejecute durante el enfriamiento de la tasa de aprendizaje, en el que una unidad recién rescatada no tendría margen para aprender.

Explicación de la invención

Cada unidad del reservorio tiene una clave de afinidad propia, un vector de excitabilidad basal, pesos de entrada de puerta y de ascenso y un vector de salida. Para cada elemento, el selector calcula una puntuación por unidad a partir de la afinidad entre una consulta derivada del elemento y la clave de cada unidad, y marca exactamente K unidades por orden de puntuación decreciente, con desempate por una identidad estable distinta del índice físico. El entrenamiento mantiene, por unidad, un estimador de uso: una media móvil exponencial de la frecuencia con la que la unidad ha sido seleccionada en los elementos válidos.

En instantes de rescate, definidos como múltiplos exactos de un intervalo de elementos aceptados, posteriores a un inicio configurado y anteriores al enfriamiento de la tasa de aprendizaje, el método identifica en cada capa las unidades

infrautilizadas: aquellas cuyo estimador de uso es inferior a una fracción configurada de la media de la capa. Ordena esas unidades por uso creciente, con desempate por identidad estable, y toma como máximo una fracción configurada del reservorio. Ordena las unidades no infrautilizadas por uso decreciente, con el mismo desempate, y asigna a cada unidad infrautilizada una donante distinta, la más usada disponible.

Para cada par, la unidad infrautilizada se convierte en gemela de su donante: su clave de afinidad pasa a ser la clave normalizada de la donante más una perturbación aleatoria generada por un generador sembrado con la semilla del modelo, el número de elementos aceptados y el índice de la capa, y se vuelve a normalizar; su excitabilidad basal, su fila del predictor de utilidad, si lo hay, y sus vectores de puerta y de ascenso se copian de la donante; su vector de salida se pone a cero. La donante no se modifica. Como la clave de la gemela está a una distancia pequeña de la clave de la donante, la gemela obtiene puntuaciones próximas a las de la donante en los mismos elementos y entra en la selección en la región de consulta en que la donante trabaja; como su vector de salida es cero, su contribución es nula en el instante del rescate, y la función de la capa solo cambia por la unidad marginal que la gemela desplaza de las K plazas. Desde la primera actualización posterior, el vector de salida de la gemela recibe gradiente cuando la gemela está en la máscara, y, con él, el resto de sus parámetros.

El estimador de uso se reparte: la donante y la gemela quedan con la mitad del valor que tenía la donante, de modo que ninguna de las dos aparece como infrautilizada en el instante siguiente y la carga estimada del par coincide con la de la donante antes del rescate. El contador de última selección de la gemela se pone al instante del rescate, de modo que su ventana de inactividad empieza de nuevo. Cuando el optimizador mantiene momentos por parámetro, los momentos de las filas copiadas se copian de la donante y los de la columna de salida anulada se ponen a cero, de modo que la gemela evoluciona como lo haría la donante y su salida crece desde cero con la escala adecuada.

El rescate es determinista: dadas la semilla, el instante y la capa, la elección de unidades y la perturbación son las mismas. La cadena de entrenamiento alinea los límites de las actualizaciones con los instantes de rescate, registra cada evento con las parejas rescatadas, y un entrenamiento retomado desde un punto de control anterior al instante repite el rescate idénticamente. Un punto de control tomado en el mismo instante lleva ya los parámetros y momentos rescatados y no lo repite.

No hay, a la fecha de esta solicitud, un ensayo del solicitante que mida la calidad de predicción con el rescate activado. El efecto técnico en el que se apoya la solicitud es

estructural y verificable por un experto sobre la realización: la gemela entra en la selección en los elementos de la donante, su contribución es nula en el instante del rescate, la donante no cambia, el estimador de uso se reparte, y la operación es reproducible bit a bit tras una retomada.

Ventajas

Una unidad que el selector había abandonado vuelve a recibir gradiente en elementos reales, en la región de consulta de una unidad activa, en lugar de en una región aleatoria. La contribución nueva nace en cero y la donante no se toca, de modo que la calidad de la capa no sufre un salto en el instante del rescate más allá del desplazamiento de la unidad marginal. La carga estimada se reparte sin volver a señalar de inmediato al par. Los momentos del optimizador acompañan a las filas, de modo que la gemela no arranca con una escala de paso incoherente. La operación se ejecuta en instantes exactos, queda registrada y sobrevive a las retomadas, lo que la hace compatible con una cadena de entrenamiento con puntos de control persistentes y con comparaciones reproducibles. La cantidad de unidades rescatadas por evento está acotada, y el enfriamiento de la tasa de aprendizaje queda libre de cirugía.

Breve descripción de los dibujos

La figura 1 muestra una unidad infrautilizada convertida en gemela de una unidad donante: clave con perturbación, pesos de entrada copiados, proyección de salida a cero. Es la figura característica para el resumen.

La figura 2 muestra la línea de elementos aceptados con los instantes de rescate, el inicio, el intervalo y la exclusión del enfriamiento.

La figura 3 muestra el efecto sobre el selector de cardinalidad exacta: la gemela entra en las K plazas de la región de consulta de la donante y desplaza a la unidad marginal; la donante permanece.

Exposición detallada de un modo de realización

Capa y estimador de uso.

La figura 1 muestra un reservorio (10) de N unidades (12), en el ejemplo N = 16384 por capa en una pila de 14 capas de dimensión de estado d = 1024. Cada unidad tiene una identidad estable (14), una clave de afinidad (40) de dimensión 32 almacenada normalizada, una excitabilidad basal escalar, una fila del predictor de utilidad de rango 8, un vector de puerta y un vector de ascenso de dimensión d, y un vector de salida (48) de dimensión d. Para cada elemento válido, la consulta se obtiene normalizando el estado de entrada del reservorio y proyectándolo a la dimensión de la clave; la puntuación de la unidad es el coseno entre la consulta y la clave, más la excitabilidad

basal y, opcionalmente, un término del predictor de utilidad. El selector marca exactamente K unidades, en el ejemplo K = 1024 por capa, por orden de puntuación decreciente e identidad estable creciente. El cálculo hacia delante usa la máscara rígida; el entrenamiento usa un estimador de paso directo alrededor del punto medio entre la K-ésima y la (K+1)-ésima puntuación.

El estimador de uso (50) de cada unidad es una media móvil exponencial, con semivida de un millón de elementos en el ejemplo, de la fracción de elementos válidos de cada actualización aceptada en los que la unidad fue seleccionada. Se actualiza al consolidar cada actualización, junto con el uso acumulado, la antigüedad de la capa en elementos y el instante de última selección de cada unidad. Estos contadores viajan en el punto de control.

Instantes de rescate.

La figura 2 muestra la línea de elementos aceptados. El rescate se ejecuta en cada múltiplo exacto (52) de un intervalo configurado, en el ejemplo 10 millones de elementos, estrictamente posterior a un inicio configurado, en el ejemplo 20 millones de elementos, y solo mientras el instante es anterior al comienzo del enfriamiento (56) de la tasa de aprendizaje cuando la receta lo tiene. La cadena de entrenamiento recorta el tamaño de la actualización que cruzaría el siguiente instante de rescate, de modo que una actualización aceptada termina exactamente en él; así el instante no depende del tamaño de lote ni del punto de control desde el que se retomó. El rescate se ejecuta después de la evaluación y de la instantánea de estado de ese instante, que describen el modelo antes de la cirugía, y antes de cualquier punto de control del mismo instante, que lleva los parámetros y momentos ya rescatados.

Identificación de infrautilizadas y donantes.

En cada capa a partir de una capa mínima configurada, en el ejemplo la capa 0 o, en una variante, las tres últimas capas, se calcula la media del estimador de uso. Es infrautilizada (42) toda unidad cuyo estimador es inferior a una fracción configurada de esa media, en el ejemplo 0,1. Si no hay ninguna, o si todas lo son, la capa no se toca en ese instante. Las infrautilizadas se ordenan por uso creciente, con desempate por identidad estable creciente, y se toman como máximo tantas como una fracción configurada del reservorio, en el ejemplo el 1 %, es decir 163 unidades por capa y evento. Las unidades no infrautilizadas se ordenan por uso decreciente, con el mismo desempate, y las primeras se asignan como donantes (44), una distinta para cada infrautilizada, de modo que ninguna donante se divide dos veces en el mismo evento. Si hay menos donantes disponibles que infrautilizadas, se rescatan tantas como donantes.

Conversión en gemela.

Un generador de números aleatorios se siembra con la suma de la semilla del modelo, el producto del número de elementos aceptados por una constante y el producto del índice de la capa por otra constante, reducida al rango del generador; en el ejemplo 1 000 003 y 7 919. Con él se genera, para cada pareja, un vector de perturbación normal de la dimensión de la clave. La clave de la gemela (46) es la normalización de la suma de la clave normalizada de la donante y la perturbación multiplicada por una escala configurada, en el ejemplo 0,05, dividida por la raíz cuadrada de la dimensión de la clave. Con esa escala, el coseno entre la clave de la gemela y la de la donante supera 0,99 en el ejemplo: la gemela obtiene puntuaciones casi iguales a las de la donante en los mismos elementos y entra en la selección donde la donante entra, pero no es idéntica, de modo que el gradiente posterior puede separarlas.

La excitabilidad basal de la gemela toma el valor de la donante; su fila del predictor de utilidad, si el predictor está activado, toma la fila de la donante; sus vectores de puerta y de ascenso toman los de la donante, de modo que la activación z de la gemela coincide con la de la donante en el instante del rescate; su vector de salida (48) se pone al vector cero. La donante conserva todos sus parámetros. Como en la solicitud del mismo solicitante sobre la ampliación del reservorio, la preservación depende del vector de salida y no de la puerta: con salida cero y puerta y ascenso no nulos, el vector de salida recibe gradiente en la primera actualización en la que la gemela está en la máscara, y a partir de entonces lo reciben la puerta, el ascenso y, por el estimador de paso directo, la clave.

Reparto del uso y contadores.

El estimador de uso de la donante y el de la gemela se ponen ambos a la mitad del valor que tenía la donante. Así la carga estimada del par es la de la donante antes del rescate, ninguna de las dos queda por debajo del umbral de infrautilización en el instante siguiente, y la donante no puede ser elegida de nuevo como donante en el mismo evento. El instante de última selección de la gemela se pone a la antigüedad actual de la capa, de modo que la ventana de inactividad con la que se cuentan las unidades muertas empieza de nuevo para ella. El uso acumulado, que es histórico, no se modifica. Cuando el regulador homeostático mantiene un término integral por unidad, el de la gemela se copia del de la donante. Dos contadores por capa, número de eventos y número de unidades rescatadas, se incrementan y viajan en el punto de control; solo existen cuando el rescate está activado, de modo que un punto de control anterior conserva exactamente su estado.

Momentos del optimizador.

Cuando el optimizador es de tipo Adam, con primer y segundo momento por parámetro, los momentos de las filas de la clave, de la excitabilidad, de la fila del predictor, de la puerta y del ascenso de la gemela se copian de las filas correspondientes de la donante, y los momentos de la columna de salida de la gemela se ponen a cero. Con momentos copiados, la gemela recibe en su primera actualización un paso de la misma escala que la donante; con la columna de salida a cero en pesos y momentos, la salida de la gemela crece desde cero con el paso que el optimizador aplica a un parámetro nuevo. El contador de pasos del optimizador es común y no se modifica.

Registro y retomada.

Cada evento se registra en el flujo de métricas de la corrida con el instante, la actualización, y por capa el número de infrautilizadas, el número de rescatadas y las parejas de índices rescatada-donante. Como la elección de unidades depende solo del estimador de uso y de las identidades, y la perturbación solo de la semilla, el instante y la capa, un entrenamiento retomado desde un punto de control anterior al instante de rescate repite el mismo evento sobre el mismo estado y produce los mismos parámetros, momentos y contadores. El solicitante ha verificado esa igualdad bit a bit en un modelo reducido, y también que una receta con enfriamiento no ejecuta rescates dentro del enfriamiento.

Selector y desplazamiento.

La figura 3 muestra, para un elemento de la región de consulta de la donante (44), las K plazas (26) del selector antes y después del rescate. Antes, la donante ocupa una plaza y la unidad marginal (58), la K-ésima por puntuación, ocupa la última. Después, la gemela (46), con puntuación casi igual a la de la donante, ocupa una plaza y la marginal queda fuera. La contribución de la gemela es nula en ese instante; la contribución de la marginal desaparece. Ese es el único cambio de la función de la capa en el instante del rescate, y está acotado por la contribución de una unidad marginal en cada elemento afectado. La donante permanece seleccionada con su contribución intacta. En los elementos fuera de la región de consulta de la donante, la selección no cambia.

Realización combinada con una pérdida de dispersión.

En una realización, el entrenamiento añade además una pérdida auxiliar por capa igual al producto del número de unidades por la suma, sobre las unidades, del producto de la fracción de rutas que recibió cada unidad en la actualización, sin

gradiente, por la media sobre los elementos de su probabilidad de selección; con carga uniforme la pérdida vale uno. Esa pérdida, conocida a granularidad de experto, se mantiene con un peso constante configurado, en el ejemplo 0,01, durante toda la corrida, en lugar de decrecer al principio. El rescate por división actúa sobre las unidades que esa pérdida no consigue mantener en uso; la pérdida actúa de forma continua sobre el encaminador. La combinación es opcional.

Comprobaciones que el experto puede automatizar.

Tras un rescate, las filas de puerta, ascenso, excitabilidad y predictor de la gemela son iguales a las de la donante; la columna de salida de la gemela es nula; el coseno entre las claves supera un umbral próximo a uno y la clave de la gemela tiene norma unidad; los estimadores de uso del par son iguales y valen la mitad del de la donante antes; la donante no ha cambiado; los contadores de eventos y de rescatadas se han incrementado. Dos rescates con la misma semilla, el mismo instante y la misma capa producen las mismas claves; instantes distintos producen claves distintas. Con una capa mínima configurada, las capas inferiores no se tocan. Con la fracción máxima configurada, no se rescatan más unidades que la fracción del reservorio. Sin unidades infrautilizadas no se rescata ninguna. Con momentos de Adam poblados, los momentos de las filas copiadas coinciden con los de la donante y los de la columna de salida son nulos. Una corrida interrumpida antes del primer instante de rescate y retomada produce, al final, los mismos parámetros y contadores que la corrida sin interrupción. Una receta con enfriamiento no registra rescates dentro del enfriamiento.

Aplicación industrial

El método se usa en el entrenamiento de modelos de secuencia con capas de reservorio direccionable, para mantener en uso la capacidad del reservorio a lo largo de entrenamientos largos, en los que la concentración de la selección deja sin gradiente a una parte de las unidades. El sistema de procesamiento de datos que entrena el modelo ejecuta el rescate como parte de su cadena de entrenamiento, en instantes alineados con las actualizaciones aceptadas, y conserva los eventos en el registro de la corrida. La inferencia no cambia: la capa servida es la misma, con las unidades rescatadas ya entrenadas.

Lista de signos de referencia

10 reservorio. 12 unidad. 14 identidad estable. 26 cuota permanente K. 40 clave de afinidad. 42 unidad infrautilizada. 44 unidad donante. 46 gemela. 48 proyección de salida anulada. 50 estimador de uso. 52 instante de rescate. 54 momentos del optimizador copiados. 56 enfriamiento excluido. 58 unidad marginal desplazada.